Анкеты волонтёров ГИМ

Многофакторный корреляционный анализ

Закрытые и структурированные поля анкет. Наборы осени 2024 и весны 2025.

Уникальные анкеты	Балл заполнен	Активность известна	Совместная модель
113	113	45 из 46 принятых	112 анкет

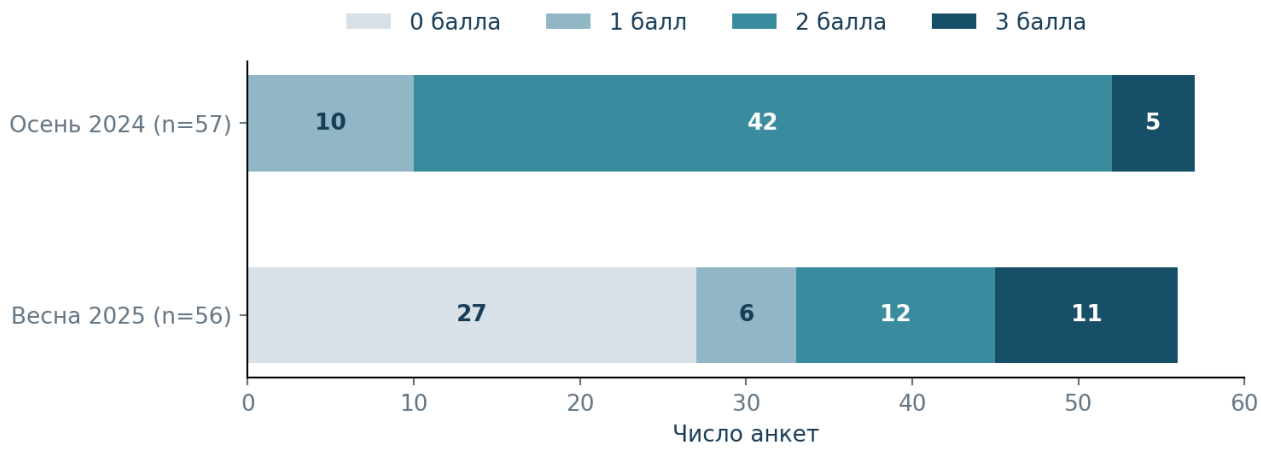
Основные результаты

Парная связь с оценкой. Интерес к фондам связан с более высоким баллом: ρ=0,280; q=0,019. Для вуза и источника набора также выявлены различия в распределениях баллов. Это связи с исторической оценкой, а не с качеством будущей работы.

При совместном учёте факторов. Множественный R=0,577; R^2=0,333; скорректированный R^2=0,252. Ни один отдельный коэффициент не проходит поправку на 12 сравнений. Размер выборки ограничивает точность оценок.

Связь с будущей активностью. Для балла и годовых часов ρ=-0,143; q=0,705; n=45. Бутстреп 95% ДИ [-0,389; 0,145]. Положительная связь на этих данных не подтверждена.

Выборки отличаются по составу баллов



В осеннем файле нет анкет с 0 баллов; в весеннем их 27 из 56. Объединённые связи могут отражать различия отбора и состава кандидатов. Сезон включён в многофакторную модель.

1. Состав данных и параметры

Единица анализа - одна анкета. Осень: 33 записи на листе «Очно 30.10» и 24 на «Дистант 29.10». Весна: 56 записей из версии для хакатона. Все 55 записей второго весеннего файла совпадают по 18 общим полям, включая ответы и результаты. Они повторно не включены. Дополнительная запись находится в строке 3 версии для хакатона.

Поле	Включение и кодирование	Доступно
Дата рождения	Возраст = год набора минус год рождения. Возраст приблизительный, без учёта дня рождения.	112
ВУЗ	МГУ / РГГУ / ВШЭ / РУДН / другое. Варианты написания объединены по названию.	113
Направления	Четыре отдельных индикатора 0/1: мероприятия, проекты, фонды, инклюзия. Допускается несколько выборов.	113
Откуда узнали	Соцсети / друзья / сайт музея / другое. Свободные уточнения внутри «другое» не интерпретируются.	113
Балл анкеты	Порядковая шкала 0-3. Анализируется как результат оценки, а не как характеристика кандидата.	113
Часы активности	Часы в год среди принятых. Нулевые часы сохранены.	45
Длительность	Только числовые значения в заявленных единицах «годы». Даты исключены.	34
Приём и участие	Показаны отдельно с сохранением неопределённых значений.	46 «ДА» / 26 «ДА»

Что исключено

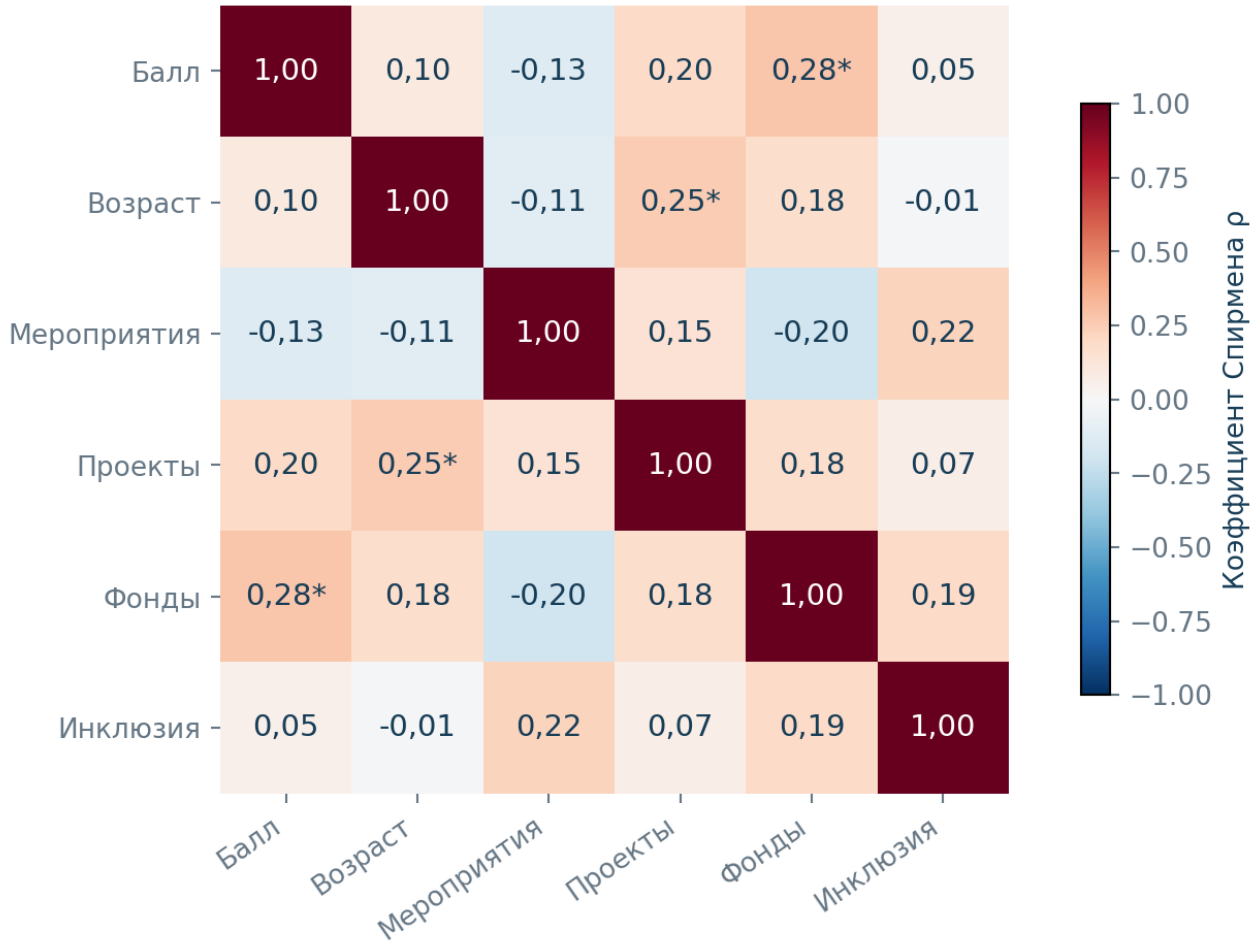
ФИО, контакты и ссылки; факультет, кафедра, курс; научные интересы, опыт, ожидания, хобби и «суперсила». Языки также исключены: в бланке не перечислены закрытые варианты, а исторические значения содержат свободные пояснения об уровнях. Тексты не оценивались и не превращались в признаки.

«Нынешний статус», готовность уделять время, медиа-направление и вариант «пока не определился» есть в новом бланке, но отсутствуют как отдельные сопоставимые поля в исторических файлах. По ним расчёт невозможен. Формат собеседования и явка не относятся к ответам анкеты и не включены.

Дату рождения рассматриваем как структурированное календарное поле. Вуз, направления и источник набора соответствуют явно заданным вариантам бланка. Служебные результаты используются только как отдельные исходы.

2. Матрица парных корреляций

Коэффициент Спирмена ρ: от -1 до +1. Для направлений 1 означает выбранный вариант, 0 - не выбранный. N=113; в парах с возрастом n=112. Звёздочка отмечает q<0,05 после поправки Бенджамини-Хохберга на 17 основных сравнений.



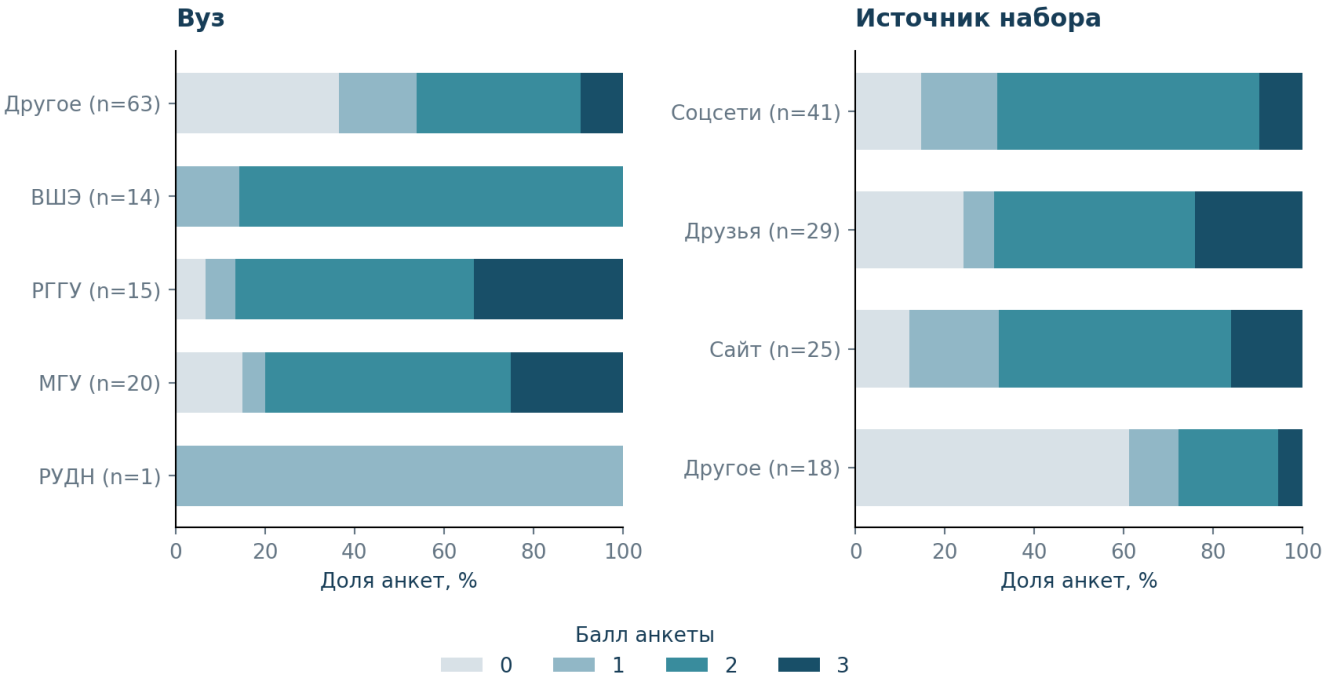
Связь с баллом	ρ	p	q	n
Возраст в год набора	0,096	0,324	0,393	112
Мероприятия	-0,126	0,191	0,271	113
Проекты	0,195	0,041	0,100	113
Фонды	0,280	0,002	0,019	113
Инклюзия	0,053	0,586	0,622	113

Для фондов 95% бутстреп-интервал ρ составляет [0,086; 0,463]. Связь неоднородна: осенью 2024 ρ=-0,088, весной 2025 ρ=0,433. Поэтому общий положительный коэффициент нельзя считать устойчивым для любого набора.

Проекты связаны с возрастом: ρ=0,253; q=0,031. Связи между направлениями характеризуют сочетания предпочтений и сами по себе не показывают результативность волонтёра.

3. Вуз и источник набора

Эти категории не имеют числового порядка. Для них рассчитан V Крамера по таблицам «категория × балл», а не корреляция произвольных цифровых кодов. V находится от 0 до 1 и не показывает знак связи.



Фактор	V Крамера	p	q	n
Вуз	0,312	0,001	0,013	113
Источник набора	0,258	0,007	0,031	113

Что видно. Распределение оценок различается между вузами и источниками набора. Перестановочный тест учитывает малые частоты ячеек, но сами размеры эффектов остаются неточными в небольших категориях.

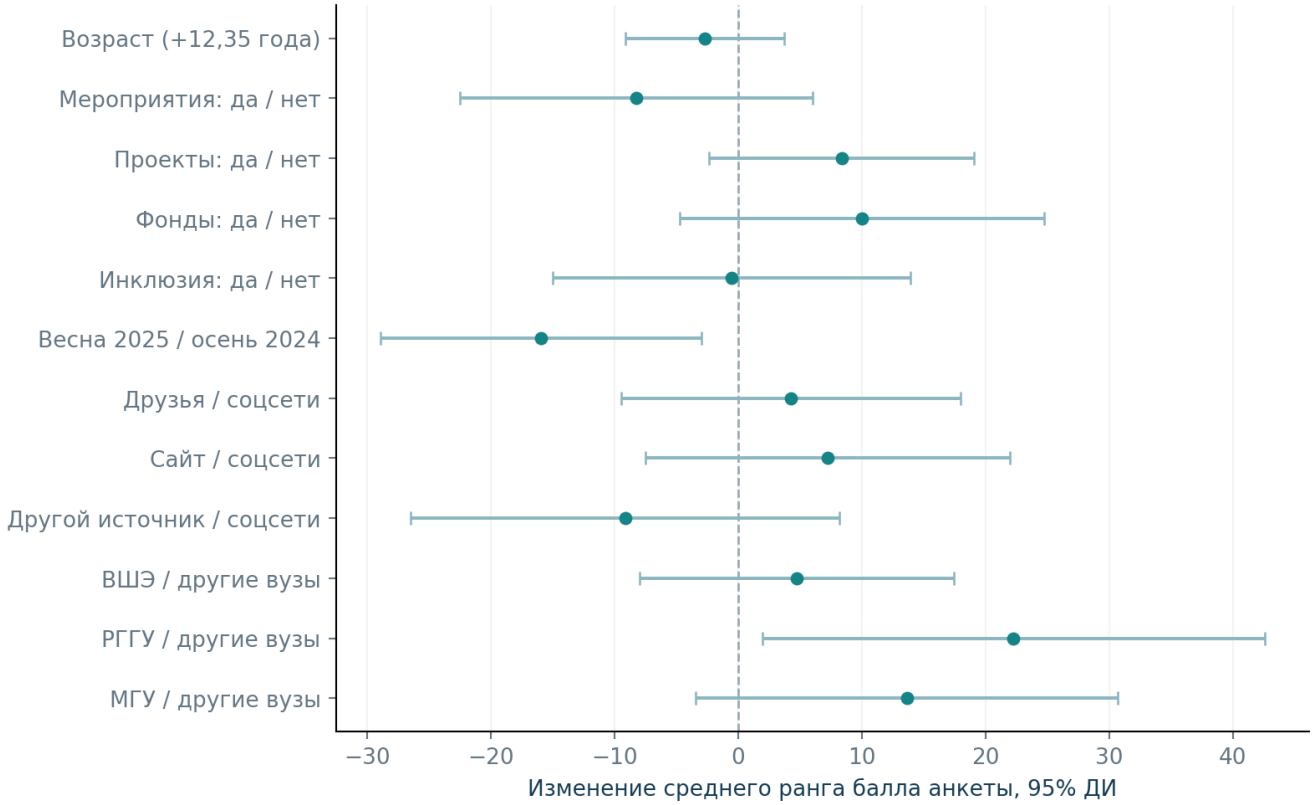
Что ограничивает вывод. Для РУДН имеется только одна запись. Отдельный эффект этой категории оценивать нельзя. В совместной модели она объединена с «другими вузами». «Другое» по вузу также включает несколько одновременно указанных вузов, если их нельзя отнести к одному варианту.

По источнику набора сохранены только три точных стандартных ответа. Все прочие формулировки, включая преподавателей и поиск в интернете, отнесены к «другое» без тематической классификации. Сравнение отражает исторические категории, а не эффективность рекламного канала или причинное влияние образования.

4. Совместный анализ факторов

Построена описательная линейная регрессия среднего ранга балла на возраст, четыре направления, вуз, источник набора и сезон. Она позволяет оценить связь каждого признака при фиксированных остальных. Это не прогностическая модель для новых кандидатов.

n	Число коэффициентов*	Множественный R	R^2	Скорр. R^2
112	12	0,577	0,333	0,252



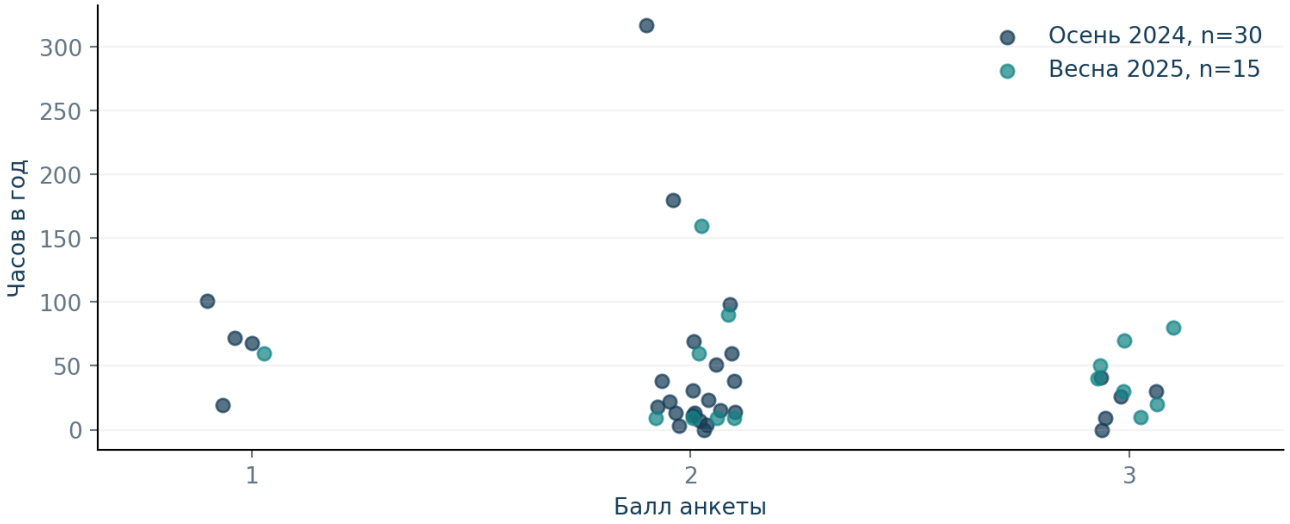
* Без константы. Возраст стандартизован: +1 стандартное отклонение = +12,35 года. Вуз: база «другое», включая РУДН; источник: база «соцсети»; сезон: база «осень 2024». На диаграмме показаны точечные оценки и отдельные 95% интервалы НСЗ. Это изменения ранга, а не баллов по шкале 0-3.

Интерпретация. До поправки интервалы сезона и РГГУ не пересекают ноль. После поправки на 12 коэффициентов у обоих q=0,192, а у остальных q ещё выше. Убедительные независимые связи при выбранном пороге не выявлены. Это не доказывает отсутствия связей.

Сезон без других факторов объясняет 13,5% вариации рангов; вся модель - 33,3%. Это показатели подгонки на той же выборке. Максимальный VIF=1,86: сильная линейная избыточность факторов не обнаружена. Полные коэффициенты приведены в приложении.

5. Связь с реальной активностью

Часы известны для 45 из 46 принятых волонтёров: 30 осенью и 15 весной. Для непринятых часы не заменялись нулём. Иначе связь с этапами отбора была бы искусственно усилена.



Точки слегка смещены по горизонтали для видимости совпадений; исходные баллы остаются целыми. По вертикали показаны исходные часы, включая 0 и максимум 317.

Фактор → часы	ρ	p	q	n
Балл анкеты	-0,143	0,345	0,705	45
Возраст в год набора	0,238	0,121	0,705	44
Мероприятия	0,031	0,846	0,907	45
Проекты	0,143	0,352	0,705	45
Фонды	-0,019	0,907	0,907	45
Инклюзия	-0,088	0,565	0,847	45

Основной результат. Ни одна из шести связей не проходит поправку на множественные сравнения. Для балла ρ=-0,143, 95% бутстреп ДИ [-0,389; 0,145]. По отдельным наборам ρ=-0,315 и 0,073; эти подгруппы малы.

Медиана активности: 24,5 часа в год осенью и 40,0 весной. Это описательное различие: календарь наблюдения и правила расчёта среднего не заданы, поэтому напрямую сравнивать эффективность наборов нельзя.

Проверка устойчивости: без приблизительного значения «около 60 часов» корреляция балла с часами равна -0,108; без записи с 317 часами -0,135. Вывод об отсутствии подтверждённой положительной связи сохраняется.

6. Активность и служебные статусы

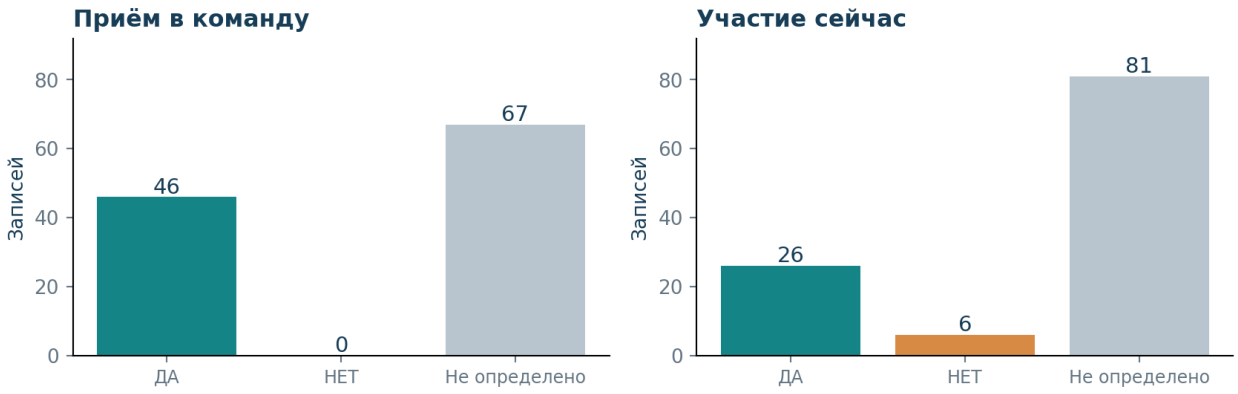
Многофакторная модель активности

Описательная модель ln(1 + часы): возраст, четыре направления и сезон. N=44 полных наблюдения; R^2=0,165, скорректированный R^2=0,030. Более крупная модель с вузом и источником не строилась из-за малого числа наблюдений.

Фактор	β	95% ДИ НСЗ	p	q
Возраст (+10,36 года)	0,343	[-0,026; 0,712]	0,068	0,405
Мероприятия: да / нет	0,129	[-1,017; 1,275]	0,821	0,978
Проекты: да / нет	0,692	[-0,367; 1,751]	0,194	0,581
Фонды: да / нет	0,017	[-1,238; 1,272]	0,978	0,978
Инклюзия: да / нет	-0,415	[-1,262; 0,433]	0,328	0,656
Весна 2025 / осень 2024	0,213	[-0,597; 1,022]	0,597	0,896

После поправки на шесть коэффициентов независимые связи не выявлены. Шкала коэффициентов логарифмическая; они не измеряют прибавку часов. Низкий скорректированный R^2 показывает ограниченную объясняющую способность этой модели.

Что можно сказать о приёме и удержании



Приём: 46 «ДА», 54 прочерка и 13 пустых значений. Явных «НЕТ» нет. Поэтому модель вероятности приёма не строилась. Участие сейчас: 26 «ДА», 6 «НЕТ», 81 прочерк. Среди принятых осенью - 16 «ДА» и 14 прочерков; весной - 10 «ДА» и 6 «НЕТ». Прочерк не приравнивался к уходу.

Длительность числом есть у 34 принятых, в том числе у 4 весенних. Ещё 9 значений ошибочно сохранены датами, 3 отсутствуют. На 34 числовых парах связь длительности с часами ρ=0,584, но она может отражать отбор, сезон и различную экспозицию. Без дат начала/окончания и единой даты среза анализ выживаемости и причинный вывод некорректны.

7. Методика и ограничения

Подготовка данных

Удалены пустые строки, а не форматированные области листов. Весенние дубли исключены по 18 общим полям без ФИО. Между сезонами точных совпадений по общим анкетным ответам не найдено, но без единого идентификатора нельзя гарантировать отсутствие повторного участия одного человека.

В дате «21.07.98» двузначный год приведён к 1998. Одно весеннее значение «03.06.1905» даёт неправдоподобный возраст и исключено только из расчётов с возрастом. Его реальный год рождения не восстанавливался. Именно эта запись является дополнительной в версии хакатона; поэтому совместная модель использует те же 112 анкет, что и объединение осени с весенним файлом из 55 строк.

Из 46 принятых у одного нет часов. «Около 60 часов в год» закодировано как 60 с отдельной проверкой исключения. Нулевые часы сохранены. Девять дат в длительности не превращались в годы. Прочерки и пустые значения не трактовались как отрицательные ответы.

Статистические процедуры

Спирмен вычислен по средним рангам с учётом совпадений. Двусторонние p получены 19 999 случайными перестановками: p=(число $|\rho^*| \geq |\rho|$ + 1)/20 000. Для V Крамера переставлялись метки балла, статистика - χ^2 Пирсона без поправки Йейтса. Seed=20261021. [1-2]

Поправка Бенджамини-Хохберга применена отдельно к 17 основным тестам (15 пар матрицы и 2 категориальных), 6 связям с часами, 12 коэффициентам основной модели и 6 коэффициентам модели часов. Использован порог $q<0,05$. Проверки разведочные: гарантии BH зависят от структуры зависимости тестов. [3]

Интервалы регрессий: ковариационная оценка HC3, t-приближение с n-k степенями свободы. Для ρ «фонды - балл» и «балл - часы» показаны процентильные 95% бутстреп-интервалы по 5 000 перевыборок анкет. Интервалы не скорректированы для одновременного покрытия. [4]

Практическое использование

Связи с баллом отражают существовавшие правила оценивания, включая текстовые критерии, которые в этот анализ не входили. Для обучения LLM это потенциальная цель воспроизведения экспертной оценки; часы активности требуют отдельной цели и независимой проверки. Эти результаты не обосновывают автоматический отсев по вузу или возрасту.

Необходимы единые идентификаторы, явные статусы «да/нет/неизвестно», корректная числовая длительность, даты вступления/выхода и общий период учёта часов. Для проверки модели на новых данных нужен отдельный, не использованный при настройке набор.

Приложение. Точные оценки и источники

Коэффициенты совместной модели балла

Фактор	β ранга	95% ДИ HC3	p	q
Возраст (+12,35 года)	-2,70	[-9,13; 3,73]	0,407	0,543
Мероприятия: да / нет	-8,26	[-22,52; 6,01]	0,254	0,498
Проекты: да / нет	8,36	[-2,35; 19,06]	0,124	0,373
Фонды: да / нет	10,03	[-4,70; 24,77]	0,180	0,431
Инклюзия: да / нет	-0,53	[-15,00; 13,94]	0,942	0,942
Весна 2025 / осень 2024	-15,94	[-28,92; -2,95]	0,017	0,192
Друзья / соцсети	4,29	[-9,43; 18,01]	0,537	0,585
Сайт / соцсети	7,23	[-7,48; 21,94]	0,332	0,498
Другой источник / соцсети	-9,14	[-26,47; 8,19]	0,298	0,498
ВШЭ / другие вузы	4,77	[-7,94; 17,47]	0,458	0,550
РГГУ / другие вузы	22,27	[1,96; 42,58]	0,032	0,192
МГУ / другие вузы	13,63	[-3,42; 30,69]	0,116	0,373

Константа: 50,44; 95% ДИ [28,59; 72,30]. Полные парные коэффициенты представлены на матрице; ниже перечислены значимые после BH связи в основной семье тестов.

Пара	Мера	Значение	p	q
Балл анкеты / Фонды	Спирмен	0,280	0,002	0,019
Возраст в год набора / Проекты	Спирмен	0,253	0,006	0,031
Вуз / Балл анкеты	V Крамера	0,312	0,001	0,013
Источник набора / Балл анкеты	V Крамера	0,258	0,007	0,031

Источники данных

«Анкеты 2024 осень(5).xlsx», листы «Очно 30.10» и «Дистант 29.10»; «2025 весна Хакатон ВШЭ(3).xlsx», лист «Ответы на форму (1)»; «Анкеты 2025 весна(5).xlsx» - проверка дублей; «Анкета волонтера. Вопросы.(9).docx» - состав закрытых вариантов и критерии оценки. Персональные строки в отчёт не включены.

Методические источники

[1] SciPy: Spearman и перестановочные тесты

[2] SciPy: V Крамера

[3] SciPy: контроль FDR

[4] Statsmodels: формула HC3

Расчёты выполнены 21 октября 2026 года. Это дата анализа, а не подтверждённая дата среза исходных данных.