1. Аудит анкет и параметры анализа

Проверка трёх таблиц и анкеты волонтёра. Исходные файлы не изменены.

Историческая оценка анкеты, решение после собеседования и последующая активность рассмотрены как разные показатели. Адреса аномалий приведены ниже.

Что содержат файлы

Файл / лист	Непустые записи	Баллы 0 / 1 / 2 / 3	Особенность
2025 весна Хакатон ВШЭ(2).xlsx / Ответы на форму (1)	56	27 / 6 / 12 / 11	Диапазон до строки 151; 94 полностью пустые строки
Анкеты 2025 весна(4).xlsx / Ответы на форму (1)	55	27 / 6 / 12 / 10	Диапазон до строки 150; 94 полностью пустые строки
Анкеты 2024 осень(4).xlsx / Очно 30.10	33	0 / 2 / 28 / 3	Есть формулы длительности
Анкеты 2024 осень(4).xlsx / Дистант 29.10	24	0 / 8 / 14 / 2	Есть ФИО и служебные комментарии

В весенних файлах 55 записей совпадают по всем 18 общим столбцам после нормализации пробелов и регистра. Версия для хакатона содержит одну дополнительную запись — строку 3. Базовый набор: 56 весенних + 57 осенних = **113 различных записей** по доступным полям. Полностью совпадающих анкет внутри этой базы не найдено; без устойчивого ID нельзя исключить повторную подачу одним человеком.

Распределение базы: 0 — 27, 1 — 16, 2 — 54, 3 — 16. Для сравнения с исторической шкалой 1–3 доступны **86 анкет**. Ноль в источнике означает «не позвали», поэтому его нельзя автоматически превращать в оценку 1. Для прогноза активности наблюдается отбор: данные есть преимущественно у принятых кандидатов.

Аномалии и последствия

Наблюдение и адрес	Что может исказить	Как обработать
55 общих записей в двух файлах весны	При простом объединении: 168 строк вместо 113; вес весны 66,1% вместо 49,6%. Копии могут попасть и в обучение, и в тест.	Использовать версию хакатона как более полный весенний снимок; хранить происхождение и fingerprint; объединять копии в одну группу при разбиении.
По 94 полностью пустые строки в весенних XLSX	Занижение полноты и неверный размер выборки	Удалять только полностью пустые записи. Нули сохранять как реальные значения.
Хакатон: C3, C34, C38, C43, C46, C52:C55 — дата 2026-05-02 вместо длительности; в другом весеннем файле — 8 тех же случаев	Средняя длительность, корреляции и целевые показатели удержания становятся недостоверными	Пометить 9 уникальных случаев как ошибку типа; не угадывать исходное число, запросить первоисточник.

Наблюдение и адрес	Что может исказить	Как обработать
Хакатон: G3 — 1905-06-03; остальные весенние значения — годы рождения	Возраст становится несопоставимым; дата выглядит подозрительно, но причина неизвестна	Отдельно хранить birth_year, birth_date, precision. Запись G3 проверить вручную, не исправлять догадкой.
Осень: 30 формул длительности; 15 используют TODAY(), остальные фиксированные даты завершения	При пересчёте меняется результат. Кэш активных записей показывает 2 года; на дату отчёта YEARFRAC от 01.11.2024 с округлением также даёт 2	Зафиксировать дату среза и хранить дату старта/завершения. Активных учитывать как ещё наблюдаемых, а не как завершивших участие.
Весна, хакатон: 13 пустых решений о приёме при балле выше 0; один из них — None, остальные пробелы	Пропуск может ошибочно превратиться в отказ	Отдельные статусы: принято / отказ / неизвестно / неприменимо. Символ «—» не приравнивать к отказу без подтверждения.
Осень: у 30 принятых 16 значений «ДА» в признаке участия, 14 — «—»	Нельзя уверенно определить долю ушедших	Уточнить смысл «—». В аналитике хранить unknown.
Весна: часы числом, текст «Около 60 часов в год», пропуски; осень: два реальных нуля. Очно 30.10!F7 = 317	Парсер теряет текстовые часы; удаление нулей завышает среднее; среднее чувствительно к большим значениям	60 хранить с флагом approximate; 0 сохранять. 317 проверить, но не удалять: это не доказанная ошибка.
В столбцах ФИО и явки есть «БЕРЕМ», «ДА», «ПРОТЕЖЕ» и другие заметки	Утечка решения при обучении на тексте строки; передача лишних персональных данных	Полностью исключить ФИО, явку и служебные заметки из признаков; контакты хранить отдельно.
В документе появились мотивация выбора ГИМ, часы в месяц, статус и медиа-направление; в старых таблицах части этих полей нет	Нельзя обучить или проверить все критерии новой анкеты на старых данных	Версионировать анкеты. Новые поля оценивать на новой экспертной разметке; отсутствующие поля не считать отрицательными.
В осени нет баллов 0; в весне 27. Среди 27 весенних нулей — 18 первокурсников	Состав выборок и практика отбора различаются; корреляция не доказывает причину отказа	Сравнивать когорты и этапы отбора отдельно. Не переносить исторические штрафы за курс и вуз в бот автоматически.

Проверка связи с результатом: в осени среди принятых с баллом 1 средняя активность — 65 часов (n=4), с баллом 2 — 48,8 (n=21), с баллом 3 — 21,2 (n=5). Это описательная статистика маленькой отобранной выборки, а не доказательство обратной зависимости. Конкретные примеры: «Очно 30.10»!B11=1, F11=101; B4=3, F4=0. Балл качества анкеты нельзя выдавать за вероятность высокой активности.

Проверены заполненность, типы, дубли, диапазоны, распределения оценок, связанные статусы, формулы и скрытые строки/столбцы. Скрытых строк и столбцов не обнаружено. Формулы в весенних файлах отсутствуют. Семантическая достоверность опыта и правдивость ответов по таблицам не проверяются.

Параметры анализа и оценивания

Параметр	Что извлекать	Роль
Мотивация, 25%	Почему ГИМ; конкретные ожидания; предполагаемый вклад; связь с задачами музея	Оценочный критерий

Параметр	Что извлекать	Роль
Соответствие направлению, 20%	Выбранные роли; интересующие задачи; соответствующие интересы; готовность обсуждать альтернативы	Оценочный критерий; узкое предпочтение само по себе не штрафуется
Навыки и опыт, 20%	Конкретные действия и результаты; коммуникация, мероприятия, медиа, инклюзия, фонды; языки и уровень	Оценочный критерий; учитывать переносимые навыки и кейс без формального опыта
Время и логистика, 15%	Часы в месяц, регулярность, доступные дни; возможность приезжать на смены или работать дистанционно	Оценочный критерий по требованиям выбранной роли
Понимание задач, 10%	Что кандидат ожидает делать; реалистичность ожиданий и готовность учиться	Оценочный критерий
Взаимодействие и ответственность, 10%	Пример совместной работы, выполнения обязательств или ответ на короткий ситуационный вопрос	Оценочный критерий; не выводить черты личности из стиля письма
Полнота и противоречия	Отвечены ли обязательные вопросы; указаны ли взаимоисключающие условия	Повод уточнить, не самостоятельный бонус за длину
Согласие и контакты	Согласие на обработку; корректность контактного канала	Условия процедуры, вне балла
Когорта, версия, оценщик, даты	Версия анкеты/рубрики; дата подачи; ID записи и источника; дата среза	Контроль воспроизводимости
Приём, удержание, часы	Раздельные исходы после подачи, сроки наблюдения, значение и точность часов	Только последующая аналитика; не входные признаки бота

Веса — **проектное предложение, не результат статистической калибровки**. Название вуза, курс, возраст, источник знакомства с программой, открытость ВК и объём текста не дают автоматических бонусов или штрафов. Занятость проверяется через фактическую доступность, география — через возможность выполнять выбранные задачи. Ограничения направления по числу мест учитываются отдельно от качества кандидата. Возрастные условия применяются только при наличии утверждённого правила программы.

Для каждого критерия q: 0 — требование роли не выполнено после уточнения; 0,5 — выполнено частично, есть конкретное основание; 1 — выполнено и подтверждено конкретным ответом. Неизвестное значение хранится как null. Пустой ответ или отсутствие формального стажа не равны q=0. Навыки и ответственность можно подтвердить коротким кейсом. LLM возвращает criterion_id, q, answer_id, короткую цитату-основание и флаги; сервер проверяет наличие цитаты в исходном ответе.

Критерий	q = 0	q = 0,5	q = 1
Мотивация	После уточнения нет ни связи с ГИМ, ни предполагаемого вклада	Есть связь с музеем или конкретная цель	Есть и осмысленная связь, и конкретный предполагаемый вклад

Критерий	q = 0	q = 0,5	q = 1
Направление	Желаемые задачи не соответствуют ни одной выбранной роли	Есть частично подходящая задача	Названы подходящие задачи и интерес к их выполнению
Навыки	Нет применимого навыка даже по уточнению/кейсу	Есть переносимый навык с примером	Есть применимый к роли навык с конкретным примером действия/результата
Доступность	Явно не может выполнять обязательный график роли	Может выполнять часть задач; подходящий ограниченный формат подтверждён	Заявленный график соответствует обязательным условиям роли
Понимание	Ожидает задачи вне программы и не готов обсуждать реальные	Понимает часть задач, готов учиться	Реалистично описывает задачи и границы роли
Ответственность	Ответ на кейс показывает игнорирование обязательств без уведомления	Есть частично подходящий способ решения	Пример/кейс содержит выполнение обязательства или своевременное уведомление и согласование

Требования к графику и задачам каждой роли должны быть утверждены музеем до запуска. Эти якоря — начальная рубрика: требуется проверка экспертами и согласование пограничных случаев.